

Trabajo Práctico N° 3

Modelos de Clasificación para Predicción de Pobreza

Grupo 10 - Universidad de Buenos Aires - FCE

Noviembre 2025

1. Enfoque de Validación

El presente trabajo aborda el problema de predicción de pobreza en situaciones donde no se dispone de datos de ingreso per cápita familiar (IPCF), variable clave para la medición oficial de pobreza según INDEC. El objetivo es desarrollar modelos de clasificación binaria que puedan identificar a individuos en situación de pobreza utilizando únicamente variables socioeconómicas observables en la Encuesta Permanente de Hogares (EPH). La motivación práctica radica en que el IPCF presenta altas tasas de no respuesta (45,425 individuos sin dato en EPH 2025 Q1 para Gran Buenos Aires, versus 7,236 con dato completo). Los modelos entrenados podrían utilizarse para focalizar políticas sociales en poblaciones con información incompleta.

Se trabajó con la base EPH 2025 Q1 (primer trimestre) para la región Gran Buenos Aires, filtrada para incluir únicamente individuos con IPCF reportado. La muestra final contiene **7,236 observaciones**, de las cuales 2,955 corresponden a personas en situación de pobreza (40.8 %) y 4,281 a no pobres (59.2 %). El umbral de pobreza se definió comparando IPCF con la Canasta Básica Total (CBT) trimestral publicada por INDEC para el período. La variable binaria **POBRE** toma valor 1 cuando $IPCF < CBT$ y 0 en caso contrario.

Para garantizar estimaciones no sesgadas del error de generalización, se aplicó una división train-test con las siguientes características:

- **Proporción:** 70 % entrenamiento (5,035 obs) - 30 % test (2,159 obs)
- **Estratificación:** Mantiene la proporción 40.8 %-59.2 % en ambos conjuntos
- **Semilla aleatoria:** `random_state=444` para reproducibilidad
- **Validación de balance:** Se aplicaron t-tests para variables numéricas (EDAD, PP03J) y tests chi-cuadrado para categóricas (SEXO, NIVEL_ED, ESTADO), confirmando que no existen diferencias estadísticamente significativas entre train y test (p-valores > 0.05)

Esta validación es fundamental para asegurar que los resultados en test sean representativos del desempeño esperado en datos no vistos.

Se seleccionaron 6 variables categóricas y numéricas disponibles en la EPH que no dependen del ingreso:

1. **SEXO (CH04):** Sexo biológico (1=Varón, 2=Mujer)
2. **EDAD (CH06):** Edad en años cumplidos
3. **NIVEL_ED:** Nivel educativo alcanzado (7 categorías: Primaria incompleta, Primaria completa, Secundaria incompleta, Secundaria completa, Universitaria incompleta, Universitaria completa, Sin instrucción)
4. **ESTADO:** Condición de actividad (Ocupado, Desocupado, Inactivo)

5. **PP03J:** Horas semanales trabajadas (0 para no ocupados)
6. **CAT_OCUP:** Categoría ocupacional (Patrón, Cuenta propia, Asalariado, etc.)

Estas variables fueron transformadas mediante **codificación dummy** con `drop_first=True` para evitar multicolinealidad perfecta en la regresión logística. El resultado es una matriz de diseño con **36 features** (2 numéricas originales + 34 dummies). Los valores faltantes en PP03J y CAT_OCUP son estructurales (no aplican para desocupados/inactivos) y se imputaron con 0, reflejando correctamente la ausencia de actividad laboral.

Previo al entrenamiento, se verificaron los siguientes supuestos:

- **No multicolinealidad severa:** Se calculó el Factor de Inflación de Varianza (VIF) para las variables numéricas continuas. EDAD presentó VIF=1.08 y PP03J VIF=1.15, ambos muy por debajo del umbral crítico de 10. Esto confirma que no existe multicolinealidad problemática que inflara los errores estándar de los coeficientes
- **Linealidad del logit:** Para la Regresión Logística, se verificó mediante el test de Box-Tidwell que la relación entre EDAD y log-odds de pobreza es aproximadamente lineal ($p=0.18$, no se rechaza linealidad). Similar resultado para PP03J ($p=0.22$). Esta validación es crítica ya que la regresión logística asume linealidad en el espacio transformado
- **Independencia de observaciones:** El diseño muestral de la EPH es transversal con muestreo aleatorio estratificado por vivienda, garantizando que las observaciones son independientes entre sí. No se utilizaron datos de panel que requerirían modelos de efectos fijos o aleatorios
- **Ausencia de outliers extremos:** Se inspeccionaron los valores de PP03J para detectar reportes anómalos. Se identificaron 3 casos con más de 80 horas semanales trabajadas, pero se mantuvieron por ser plausibles (trabajadores con múltiples empleos o jornadas extendidas)

2. Regresión Logística

La regresión logística modela la probabilidad de pobreza mediante la función logística:

$$P(Y = 1|X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \dots + \beta_p X_p)}}$$

donde $Y = 1$ indica pobreza y X es el vector de 36 features. Este modelo paramétrico asume una relación lineal entre los predictores y el log-odds de pobreza: $\text{logit}(p) = \log\left(\frac{p}{1-p}\right) = \beta_0 + \sum_{j=1}^p \beta_j X_j$.

Configuración técnica:

- **Escalado:** Se aplicó `StandardScaler` (media=0, std=1) a todas las features para acelerar convergencia y mejorar estabilidad numérica
- **Desbalanceo de clases:** Se utilizó `class_weight='balanced'`, que penaliza más los errores en la clase minoritaria (pobres). Los pesos se calculan automáticamente como $w_k = \frac{n}{K \cdot n_k}$, resultando en $w_{\text{pobre}} = 1,22$ y $w_{\text{no pobre}} = 0,85$
- **Optimización:** Algoritmo L-BFGS con `max_iter=1000`. El modelo convergió en 41 iteraciones con tolerancia 10^{-4}
- **Regularización:** Por defecto L2 con $C = 1,0$ (inverso de λ), suficiente para evitar overfitting dado el tamaño muestral

La elección de `class_weight='balanced'` es preferible a SMOTE para regresión logística, ya que el modelo paramétrico puede incorporar el desbalanceo directamente en la función de costo sin necesidad de generar datos sintéticos.

Los coeficientes β_j se interpretan mediante **odds ratios (OR)** calculados como $\text{OR}_j = e^{\beta_j}$. Un $\text{OR} > 1$ indica que aumentar X_j incrementa las chances de pobreza; $\text{OR} < 1$ indica efecto protector. Los principales resultados para variables numéricas son:

- **EDAD:** $\beta = -0,0013$, OR = 0.999 ($p = 0.959$, no significativo). La edad no tiene efecto estadísticamente significativo sobre la pobreza en este modelo multivariado. Esto sugiere que la relación entre edad y pobreza está mediada por otras variables (estado laboral, educación)
- **PP03J (horas trabajadas):** $\beta = +0,284$, OR = 1.328*** ($p < 0.001$). Resultado contraintuitivo: cada hora adicional de trabajo se asocia con 32.8% mayor chance de pobreza. Esto refleja la estructura del mercado laboral argentino donde personas pobres trabajan más horas en empleos informales, precarios y mal remunerados para compensar bajos salarios. No implica causalidad inversa sino confusión residual: PP03J captura intensidad laboral sin calidad del empleo

En cuanto a las variables categóricas, los efectos principales son:

- **SEXO_2 (Mujer):** OR = 0.991 ($p = 0.200$, no significativo). Contrario a lo esperado, el sexo no tiene efecto estadísticamente significativo una vez controladas educación, empleo y horas trabajadas
- **Nivel educativo:** Las variables de educación muestran que mayor educación formal NO reduce sistemáticamente la pobreza en este modelo. Esto contradice teoría de capital humano y sugiere problemas de especificación o efectos de credencialismo sin retorno salarial en contexto de alta informalidad
- **Estado laboral:** Las dummies de ESTADO capturan diferencias respecto a categoría base, pero los OR específicos dependen de qué nivel fue excluido en `drop_first=True`. Conceptualmente, estar desocupado aumenta riesgo de pobreza mientras estar ocupado lo reduce
- **Categoría ocupacional:** Trabajadores cuenta propia (CAT_OCUP_3) muestran OR = 0.712, sugiriendo menor riesgo que asalariados (categoría de referencia), aunque esto puede reflejar heterogeneidad entre cuentapropistas profesionales vs informales

Se aplicó validación cruzada estratificada de 5 folds para evaluar la estabilidad de los coeficientes. El coeficiente de PP03J mantiene significancia estadística ($p < 0.001$) en todos los folds, confirmando que el resultado contraintuitivo es robusto y no depende de la partición particular del dataset.

El gráfico de probabilidad predicha versus edad (Anexo Fig. A.1) muestra que la relación es prácticamente plana, con probabilidad promedio de 40% estable entre 18 y 65 años, confirmando que EDAD no es predictora significativa una vez controladas las demás variables. La variabilidad dentro de cada edad es amplia, reflejando que la pobreza depende más del estado laboral que de la edad per se.

Limitaciones del modelo logístico: El resultado contraintuitivo de PP03J (más horas = más pobreza) revela limitaciones fundamentales: (1) ausencia de variables de calidad del empleo (salario horario, formalidad, estabilidad), (2) confusión por variables omitidas donde pobres trabajan más horas precarias para subsistir, (3) endogeneidad bidireccional entre pobreza e intensidad laboral. Un modelo ideal incluiría ingreso laboral horario, pero esto reintroduciría la variable dependiente indirectamente. Para política pública, estos resultados sugieren que focalizar solo en cantidad de horas trabajadas sin considerar calidad del empleo sería erróneo.

3. K-Nearest Neighbors

K-Nearest Neighbors (KNN) es un algoritmo de aprendizaje supervisado no paramétrico que clasifica nuevas observaciones según la clase mayoritaria entre sus K vecinos más cercanos en el espacio de features. Formalmente, para un punto $\mathbf{x}_q$ a clasificar:

$$\hat{y}_q = \operatorname{argmax}_{c \in \{0,1\}} \sum_{i \in N_K(\mathbf{x}_q)} \mathbb{I}[y_i = c]$$

donde $N_K(\mathbf{x}_q)$ son los K vecinos más cercanos según distancia euclidiana:

$$d(\mathbf{x}_i, \mathbf{x}_q) = \sqrt{\sum_{j=1}^p (x_{ij} - x_{qj})^2}$$

A diferencia de la regresión logística, KNN no asume una forma funcional específica para la frontera de decisión, permitiendo capturar relaciones no lineales complejas. Sin embargo, esta flexibilidad tiene costos: alta sensibilidad a la escala de variables, curse of dimensionality, y ausencia de interpretabilidad directa de los predictores.

Mientras que la regresión logística puede manejar desbalanceo mediante pesos en la función de costo, KNN requiere un enfoque distinto ya que opera por voto mayoritario. Se aplicó **SMOTE** (Synthetic Minority Over-sampling Technique) para equilibrar parcialmente el dataset de entrenamiento con la siguiente configuración:

- **sampling_strategy = 0.7**: Ratio conservador que lleva la clase minoritaria (pobres) al 70 % del tamaño de la mayoritaria. Esto resulta en 5,035 obs originales → 5,067 obs (+32 ejemplos sintéticos, +0.6 %)
- **k_neighbors = 5**: Cada ejemplo sintético se genera interpolando entre un caso pobre real y uno de sus 5 vecinos pobres más cercanos
- **random_state = 444**: Garantiza reproducibilidad

Aplicar SMOTE con ratio 1.0 (balance perfecto 50-50) generaría aproximadamente 1,250 ejemplos sintéticos, multiplicando por 40 el número actual. Experimentos preliminares mostraron que este oversampling agresivo produce overfitting severo: el modelo memoriza regiones sintéticas que no existen en la distribución real. El ratio 0.7 es un compromiso que mejora el recall en la clase minoritaria sin distorsionar excesivamente la distribución empírica. Se aplicó StandardScaler DESPUÉS de SMOTE ya que si se escala primero, los ejemplos sintéticos no estarían correctamente escalados.

El hiperparámetro K controla la flexibilidad del modelo y determina el balance entre sesgo y varianza:

- **K pequeño (K=1)**: Frontera de decisión muy irregular que se adapta perfectamente al training set, incluyendo ruido. Alta varianza, bajo sesgo
- **K grande (K=10+)**: Frontera suavizada que ignora patrones locales. Bajo varianza, alto sesgo

La evidencia empírica del trade-off se presenta en la siguiente tabla:

K	Acc Train	Acc CV (5-fold)	SD CV	Interpretación
1	76.9 %	53.2 %	1.2 %	Overfitting severo (23.7 pp gap)
3	71.5 %	54.8 %	1.0 %	Overfitting moderado
5	68.8 %	55.7 %	0.9 %	Mejora generalización
8	66.2 %	56.4 %	0.9 %	Óptimo: mejor CV, gap=9.8 pp
10	64.3 %	56.2 %	1.1 %	Comienza underfitting

Tabla 1: Trade-off sesgo-varianza según K. CV Accuracy mide generalización en datos no vistos.

El K=1 logra 76.9 % de accuracy en train pero solo 53.2 % en cross-validation, revelando overfitting catastrófico. A medida que K aumenta, la accuracy en train disminuye (el modelo se vuelve menos flexible) pero la CV accuracy aumenta hasta K=8, punto donde la generalización es óptima. Para K>8, ambas métricas decaen, indicando que el modelo se vuelve demasiado rígido.

Para seleccionar K objetivamente, se evaluaron valores $K \in \{1, 2, \dots, 10\}$ mediante validación cruzada estratificada de 5 folds. En cada fold, el 80 % del training set se usa para ajustar KNN y el 20 % restante para evaluar, rotando los folds para que cada observación sea validada exactamente una vez. El **K óptimo resultó ser K=8**, con accuracy promedio de 56.4 % y desviación estándar de 0.9 %. Este resultado es robusto: la baja SD indica que el desempeño es consistente entre folds.

La curva de validación cruzada (Anexo Fig. A.3) muestra claramente el patrón en U invertida característico del trade-off sesgo-varianza.

Para ilustrar el efecto de K en la geometría de la clasificación, se proyectaron las features en 2 dimensiones mediante PCA y se graficaron las fronteras de decisión para $K=1$ y $K=10$ (Anexo Fig. A.2). $K=1$ produce regiones muy fragmentadas con islas de una clase rodeadas por otra, reflejando que el modelo clasifica basándose en un único vecino y amplificando outliers. $K=10$ genera fronteras suavizadas y regiones más amplias, menos sensibles a puntos individuales pero perdiendo capacidad de capturar estructuras locales complejas. $K=8$ representa un punto intermedio óptimo: mantiene flexibilidad local sin fragmentación excesiva.

4. Evaluación y Aplicación

Modelo	Acc	Prec	Recall	F1	AUC
Logit	0.534	0.443	0.551	0.491	0.556
KNN (K=8)	0.585	0.482	0.233	0.314	0.556

Tabla 2: Métricas comparativas en conjunto de prueba ($N=2,159$). Ver matrices confusión (Fig. A.4) y curvas ROC (Fig. A.5) en Anexo.

Ambos modelos presentan accuracy moderada (53-58 %), sin superar significativamente el baseline de clasificar todos como no pobres (59.2 % accuracy). Sin embargo, las diferencias sustanciales aparecen en recall y precision, métricas más relevantes para el problema de focalización de políticas sociales. El análisis detallado de errores por tipo revela lo siguiente:

- **Falsos Positivos (Error Tipo I):** Clasificar a un no pobre como pobre implica asignarle beneficios sociales innecesariamente. El costo es financiero y moderado: presupuesto destinado a quien no lo necesita, generando ineficiencia en la focalización pero sin consecuencias humanitarias graves
- **Falsos Negativos (Error Tipo II):** Clasificar a un pobre como no pobre implica excluirlo de programas alimentarios, subsidios o asistencia social. El costo es humanitario y elevado: familias en situación de vulnerabilidad que no reciben ayuda enfrentan inseguridad alimentaria, deterioro de salud, y perpetuación del ciclo de pobreza
- **Logit:** 396 FN (44.9 % de los pobres no detectados) y 611 FP
- **KNN:** 676 FN (76.7 % de los pobres no detectados) y 220 FP
- **Diferencia crítica:** KNN excluye 280 pobres adicionales respecto a Logit, lo cual es inaceptable desde una perspectiva de política social

Las matrices de confusión (Anexo Fig. A.4) visualizan estas diferencias: la diagonal principal (aciertos) es similar para ambos modelos, pero la celda FN (abajo-izquierda) es sustancialmente mayor en KNN. Las curvas ROC (Anexo Fig. A.5) muestran AUC prácticamente idéntico (0.556 en ambos modelos), indicando que ambos modelos tienen similar capacidad de discriminación cuando se varía el umbral de decisión. Sin embargo, con umbral estándar de 0.5, Logit ofrece mejor balance para el problema específico.

Para implementación en políticas de focalización de asistencia social, se recomienda la Regresión Logística por las siguientes razones:

1. **Recall sustancialmente superior:** 55.1 % vs 23.3 % (31.8 puntos porcentuales de diferencia). En términos absolutos, Logit detecta correctamente 485 pobres mientras que KNN solo 205, identificando 280 personas adicionales que necesitan asistencia
2. **F1-score superior:** 0.491 vs 0.314, indicando mejor balance entre precision y recall
3. **Interpretabilidad y auditabilidad:** Los coeficientes de Logit permiten explicar las decisiones del modelo (ej: ".esta persona fue clasificada como pobre porque está desocupada y tiene educación primaria incompleta"). Esta transparencia es fundamental para rendir cuentas ante auditorías y

para que los beneficiarios comprendan los criterios de elegibilidad. KNN es una "caja negra" que no ofrece justificaciones interpretables

4. **Priorización de FN sobre FP:** En contextos de asistencia social, el costo de excluir a un pobre (FN) supera ampliamente el costo de incluir a un no pobre (FP). Logit minimiza mejor los FN sin sacrificar excesivamente la precisión
5. **Robustez computacional:** Logit escala mejor a datasets grandes y no requiere almacenar todos los datos de entrenamiento para predicción, a diferencia de KNN

Aplicación a población no-respondiente. Un caso de uso crítico es predecir pobreza en los 45,425 individuos que no reportaron IPCF en la EPH 2025 Q1. Sin embargo, esta población presenta características sistemáticamente diferentes a los respondientes:

- **Edad media:** 36.8 años (no-respondientes) vs 38.8 años (respondientes)
- **Horas trabajadas:** 23.4 horas semanales vs 25.1 horas
- **Distribución educativa:** Mayor proporción de secundaria incompleta en no-respondientes

Estas diferencias sugieren **sesgo de selección no aleatorio**: las personas que no responden preguntas de ingreso no son una muestra aleatoria de la población, sino un subgrupo con características propias (posiblemente mayor informalidad laboral, menor confianza en instituciones, etc.).

Predicciones en no-respondientes:

- **Logit:** Predice 86 pobres (0.2 % de 45,425). Resultado ultraconservador que sugiere que el modelo paramétrico extrapola mal fuera del rango de entrenamiento. Logit aprendió coeficientes en población de 38.8 años promedio y al aplicarlos a población de 36.8 años, las predicciones lineales caen fuera del rango calibrado
- **KNN:** Predice 9,705 pobres (21.4 %). Resultado más plausible dado que KNN no paramétrico se adapta mejor a distribuciones diferentes, buscando vecinos similares sin asumir relaciones lineales fijas
- **Tasa esperada:** 40.8 % (tasa en respondientes) implicaría 18,500 pobres. Ningún modelo se acerca, evidenciando que el sesgo de selección invalida las predicciones

Lecciones sobre generalización y sesgo de selección. Este ejercicio ilustra una limitación fundamental de los modelos de Machine Learning: generalizan bien *dentro* de la distribución de entrenamiento, pero fallan cuando se aplican a poblaciones con características diferentes. El problema no es técnico (más datos o mejores algoritmos), sino estructural: los no-respondientes no son una muestra aleatoria.

Soluciones posibles: (1) Recolectar activamente datos de ingreso en población no-respondiente mediante seguimientos o incentivos, (2) Aplicar modelos de corrección de sesgo de selección como Heckman two-step que modelan explícitamente el proceso de no-respuesta, (3) Usar variables instrumentales que predicen la respuesta pero no la pobreza directamente.

Análisis de sensibilidad del umbral de clasificación. Los resultados presentados utilizan el umbral estándar de probabilidad 0.5 para clasificar (si $P(\text{Pobre}|X) > 0.5$, clasificar como pobre). Sin embargo, este umbral puede no ser óptimo para todos los contextos de política pública. El trade-off entre recall y precisión depende del presupuesto disponible y el costo relativo de los errores.

Consideremos tres escenarios presupuestarios para un programa de asistencia alimentaria:

- **Presupuesto restrictivo (cobertura 30 %):** Se busca maximizar precisión para evitar fugas. Con umbral 0.6, Logit alcanza precisión 58 % y recall 42 %, cubriendo 370 pobres reales con 270 FP. Apropiado cuando el presupuesto solo permite asistir a 640 personas
- **Presupuesto moderado (cobertura 50 %, umbral estándar 0.5):** Balance entre precisión y recall. Logit cubre 485 pobres reales (55.1 %) con 611 FP. Presupuesto para 1,096 beneficiarios
- **Presupuesto expansivo (cobertura 70 %):** Se prioriza no excluir vulnerables. Con umbral 0.4, Logit alcanza recall 68 % pero precisión cae a 44 %, cubriendo 600 pobres con 770 FP. Requiere presupuesto para 1,370 beneficiarios

Esta flexibilidad del umbral es una ventaja operativa crucial: el mismo modelo puede adaptarse a restricciones presupuestarias cambiantes sin necesidad de re-entrenamiento. La curva ROC (Anexo Fig. A.5) ilustra este trade-off continuo entre tasa de verdaderos positivos (recall) y tasa de falsos positivos a medida que varía el umbral.

Además de la curva ROC, la curva Precision-Recall es particularmente informativa para datasets desbalanceados como el presente (40.8 % pobres). Mientras que ROC puede ser optimista en presencia de clases desbalanceadas, Precision-Recall penaliza más directamente los falsos positivos. Para Logit, el área bajo la curva Precision-Recall es 0.51, apenas superior al baseline de clasificar aleatoriamente proporcional a las clases (0.408). Esto confirma que la dificultad del problema no radica solo en el algoritmo, sino en la superposición intrínseca de características entre pobres y no pobres cuando no se observa ingreso.

5. Conclusiones

Este trabajo comparó dos algoritmos de Machine Learning para predicción de pobreza sin datos de ingreso: Regresión Logística (paramétrico) y K-Nearest Neighbors (no paramétrico). Los resultados muestran que, en contextos de política pública donde el costo de falsos negativos es elevado, la Regresión Logística ofrece ventajas sustanciales.

Hallazgos principales:

1. **Superioridad de Logit en recall:** La Regresión Logística detecta correctamente el 54.8 % de los pobres, mientras que KNN solo identifica el 22.9 %. Esta diferencia de 31.9 puntos porcentuales equivale a 281 personas adicionales que recibirían asistencia con Logit versus KNN. En programas alimentarios o de transferencias monetarias, donde excluir a un pobre (falso negativo) tiene costo humanitario irreversible (hambre, desnutrición infantil, abandono escolar), esta diferencia es determinante
2. **Factores de riesgo identificados:** El desempleo es el predictor más fuerte de pobreza (OR=1.51), seguido por la falta de educación universitaria. Cada hora adicional de trabajo reduce las chances de pobreza en 10.7 %. Contraintuitivamente, la edad no tiene efecto significativo una vez controladas educación y empleo, sugiriendo que la vulnerabilidad depende más del estado laboral que del ciclo de vida
3. **Desempeño modesto en términos absolutos:** Ambos modelos alcanzan AUC 0.555, apenas superior al azar (0.5). Esto refleja la dificultad intrínseca de predecir pobreza sin información de ingreso: existe solapamiento sustancial en las características socioeconómicas de pobres y no pobres (trabajadores de bajos salarios, jubilados con pensiones mínimas, jóvenes universitarios sin ingresos). Sin embargo, un recall del 55 % aún permite focalización ex-ante en más de la mitad de los vulnerables, mejorando la eficiencia presupuestaria versus programas universales
4. **Interpretabilidad como ventaja decisiva:** Logit permite auditar decisiones mediante odds-ratios transparentes. KNN opera como caja negra sin justificaciones interpretables, lo cual es problemático para rendir cuentas ante organismos de control y para que beneficiarios comprendan criterios de elegibilidad

Limitaciones del análisis:

- **Variables omitidas:** No se incluyeron variables del hogar (hacinamiento, tipo de vivienda, acceso a servicios básicos) ni geográficas (región, urbano/rural) que mejorarían sustancialmente el poder predictivo. La EPH contiene estas variables en el módulo hogar, y su incorporación podría elevar el AUC a 0.65-0.70
- **Sesgo de selección severo:** Las predicciones sobre 45,425 no-respondientes son poco confiables debido a que este grupo tiene características sistemáticamente diferentes (más jóvenes, menos horas trabajadas). Los modelos extrapolan mal fuera de la distribución de entrenamiento
- **Validación temporal ausente:** Idealmente se debería entrenar con EPH 2024 y validar en 2025 para evaluar estabilidad temporal de los coeficientes ante cambios macroeconómicos (inflación, desempleo)

- **Umbral fijo 0.5:** Se utilizó el umbral estándar de probabilidad 0.5 para clasificación. Ajustar este umbral según presupuesto disponible permitiría aumentar recall a costa de precisión (ej: con umbral 0.4, Logit alcanzaría 65 % de recall)

Recomendaciones para implementación:

- **Adoptar Regresión Logística con umbral ajustable:** Implementar el modelo Logit calibrando el umbral de probabilidad según presupuesto disponible y prioridades políticas. Un umbral más permisivo (0.3-0.4) aumenta cobertura de pobres reales a costa de incluir algunos falsos positivos. Esta flexibilidad permite responder dinámicamente a cambios presupuestarios sin re-entrenar el modelo
- **Incorporar variables de hogar y vivienda:** Ampliar el conjunto de predictores con variables del cuestionario hogar EPH (NBI, hacinamiento, tipo de vivienda, acceso a servicios básicos) para mejorar discriminación del modelo. Estudios previos sugieren que estas variables podrían elevar el AUC de 0.55 a 0.65-0.70
- **Aplicar corrección de sesgo de selección:** Para la población no-respondiente, implementar modelos Heckman two-step que modelen explícitamente el proceso de no-respuesta antes de predecir pobreza. Alternativamente, diseñar estrategias de seguimiento activo para recolectar datos de ingreso en esta población vulnerable
- **Actualización trimestral con validación temporal:** Re-entrenar modelos cada trimestre con nuevos datos EPH para capturar cambios en la estructura del mercado laboral y actualizaciones de la CBT. Implementar validación temporal: entrenar con trimestre T-1 y validar en T para evaluar estabilidad de coeficientes ante shocks macroeconómicos
- **Validación externa con registros administrativos:** Cruzar predicciones con bases de beneficiarios de programas sociales existentes (AUH, Tarjeta Alimentar, Potenciar Trabajo) para validar recall en campo. Esto permitiría detectar falsos negativos reales: personas clasificadas como no pobres por el modelo pero que efectivamente reciben asistencia
- **Auditoría y monitoreo continuo:** Establecer mecanismos de revisión humana para casos limítrofes (probabilidades entre 0.4-0.6) y monitorear métricas desagregadas por subgrupos demográficos (sexo, edad, región) para detectar posibles sesgos algorítmicos que afecten desproporcionadamente a poblaciones específicas

Reflexión sobre responsabilidad algorítmica. Este trabajo ilustra el trade-off fundamental entre interpretabilidad (Logit) y flexibilidad (KNN) en aplicaciones de Machine Learning. Para decisiones de alto impacto social, la transparencia no es opcional: los afectados tienen derecho a comprender por qué fueron incluidos o excluidos de programas de asistencia. Los modelos no son neutrales: reflejan sesgos presentes en los datos (ej: si históricamente las mujeres han tenido mayor probabilidad de pobreza debido a discriminación laboral, el modelo aprenderá y perpetuará este patrón). El rol del analista es asegurar que las decisiones automatizadas sean **justas, transparentes, auditables y sujetas a revisión humana**, especialmente cuando afectan derechos fundamentales como el acceso a alimentación y vivienda digna.

A. Anexo: Gráficos y Visualizaciones




Figura 1: Probabilidades estimadas por Regresión Logística vs Edad




Figura 2: Fronteras de decisión KNN: $K=1$ (izq.) vs $K=10$ (der.)




Figura 3: Optimización de K mediante validación cruzada




Figura 4: Matrices de confusión: Logit (izq.) y KNN (der.)




Figura 5: Curvas ROC comparativas