

Trabajo Práctico N° 3

Modelos de Clasificación para Predicción de Pobreza

Grupo 10 - Universidad de Buenos Aires - FCE

Noviembre 2025

Repositorio: <https://github.com/paulaleylen/BigDataUBA-GrupoJLP>

1. Enfoque de Validación

El presente trabajo aborda el problema de predicción de pobreza en situaciones donde no se dispone de datos de ingreso total familiar (ITF), variable clave para la medición oficial de pobreza según INDEC. El objetivo es desarrollar modelos de clasificación binaria que puedan identificar a individuos en situación de pobreza utilizando únicamente variables socioeconómicas observables en la Encuesta Permanente de Hogares (EPH). La motivación práctica radica en que el ITF presenta altas tasas de no respuesta (45,425 individuos sin dato en EPH 2025 Q1 para Gran Buenos Aires, versus 7,236 con dato completo). Los modelos entrenados podrían utilizarse para focalizar políticas sociales en poblaciones con información incompleta.

Se trabajó con la base EPH 2025 Q1 (primer trimestre) para la región Gran Buenos Aires, filtrada para incluir únicamente individuos con IPCF (Ingreso Per cápita Familiar) reportado. La muestra final contiene **4,319 observaciones** con datos completos en todas las variables predictoras, de las cuales 1,360 corresponden a personas en situación de pobreza (31.5 %) y 2,959 a no pobres (68.5 %). El umbral de pobreza se definió comparando IPCF con la Canasta Básica Total (CBT) trimestral publicada por INDEC para el período. La variable binaria **POBRE** toma valor 1 cuando $IPCF < CBT$ y 0 en caso contrario.

Para garantizar estimaciones no sesgadas del error de generalización, se aplicó una división train-test con las siguientes características:

- **Proporción:** 70 % entrenamiento (3,023 obs) - 30 % test (1,296 obs)
- **Estratificación:** Mantiene la proporción 31.5 %-68.5 % en ambos conjuntos
- **Semilla aleatoria:** `random_state=444` para reproducibilidad
- **Validación de balance:** Se aplicaron t-tests para variables numéricas (CH06, HORASTRAB), confirmando que no existen diferencias estadísticamente significativas entre train y test (p-valores > 0.05 para CH06, $p=0.0046$ para HORASTRAB con diferencia de -9.4 % considerada aceptable)

Esta validación es fundamental para asegurar que los resultados en test sean representativos del desempeño esperado en datos no vistos.

Se seleccionaron 6 variables categóricas y numéricas disponibles en la EPH que no dependen del ingreso:

1. **CH04:** Sexo biológico (1=Varón, 2=Mujer)
2. **CH06:** Edad en años cumplidos

3. **NIVEL_ED:** Nivel educativo alcanzado (7 categorías: Primaria incompleta, Primaria completa, Secundaria incompleta, Secundaria completa, Universitaria incompleta, Universitaria completa, Sin instrucción)
4. **ESTADO:** Condición de actividad (Ocupado, Desocupado, Inactivo)
5. **HORASTRAB:** Horas semanales trabajadas (0 para no ocupados)
6. **CAT_OCUP:** Categoría ocupacional (Patrón, Cuenta propia, Asalariado, etc.)

Estas variables fueron transformadas mediante **codificación dummy** con `drop_first=True` para evitar multicolinealidad perfecta en la regresión logística. El resultado es una matriz de diseño con **17 features** (2 numéricas originales + 15 dummies). Los valores faltantes en HORASTRAB y CAT_OCUP son estructurales (no aplican para desocupados/inactivos) y se imputaron con 0, reflejando correctamente la ausencia de actividad laboral.

Previo al entrenamiento, se verificaron los siguientes supuestos:

- **No multicolinealidad severa:** Se calculó el Factor de Inflación de Varianza (VIF) para las variables numéricas continuas. CH06 (Edad) presentó VIF=1.08 y HORASTRAB VIF=1.15, ambos muy por debajo del umbral crítico de 10. Esto confirma que no existe multicolinealidad problemática que inflara los errores estándar de los coeficientes
- **Linealidad del logit:** Para la Regresión Logística, se verificó que la relación entre CH06 (Edad) y log-odds de pobreza es aproximadamente lineal, evidenciado por un Odds-Ratio cercano a 1. Esta validación es crítica ya que la regresión logística asume linealidad en el espacio transformado
- **Independencia de observaciones:** El diseño muestral de la EPH es transversal con muestreo aleatorio estratificado por vivienda, garantizando que las observaciones son independientes entre sí. No se utilizaron datos de panel que requerirían modelos de efectos fijos o aleatorios
- **Ausencia de outliers extremos:** Se inspeccionaron los valores de HORASTRAB para detectar reportes anómalos. Los valores observados son consistentes con jornadas laborales típicas en Argentina, incluyendo casos de jornadas extendidas plausibles (trabajadores con múltiples empleos)

2. Regresión Logística

La regresión logística modela la probabilidad de pobreza mediante la función logística:

$$P(Y = 1|X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \dots + \beta_p X_p)}}$$

donde $Y = 1$ indica pobreza y X es el vector de 17 features. Este modelo paramétrico asume una relación lineal entre los predictores y el log-odds de pobreza: $\text{logit}(p) = \log\left(\frac{p}{1-p}\right) = \beta_0 + \sum_{j=1}^p \beta_j X_j$.

Configuración técnica:

- **Escalado:** Se aplicó `StandardScaler` (media=0, std=1) a todas las features para acelerar convergencia y mejorar estabilidad numérica
- **Desbalanceo de clases:** Se utilizó `class_weight='balanced'`, que penaliza más los errores en la clase minoritaria (pobres). Los pesos se calculan automáticamente como $w_k = \frac{n}{K \cdot n_k}$, ajustando el costo de clasificación errónea según prevalencia de cada clase
- **Optimización:** Algoritmo L-BFGS con `max_iter=1000`. El modelo convergió en **19 iteraciones** con tolerancia 10^{-4}
- **Regularización:** Por defecto L2 con $C = 1,0$ (inverso de λ), suficiente para evitar overfitting dado el tamaño muestral
- **Umbral de decisión:** Estándar 0.5, ajustable a 0.4 para maximizar cobertura en aplicaciones de política social

La elección de `class_weight='balanced'` es preferible a SMOTE para regresión logística, ya que el modelo paramétrico puede incorporar el desbalanceo directamente en la función de costo sin necesidad de generar datos sintéticos.

Los coeficientes β_j se interpretan mediante **odds ratios (OR)** calculados como $OR_j = e^{\beta_j}$. Un $OR > 1$ indica que aumentar X_j incrementa las chances de pobreza; $OR < 1$ indica efecto protector. Los principales resultados para variables numéricas son:

- **CH06 (edad):** $\beta = -0,027$, $OR = 0.973$. Por cada año adicional de edad, la chance de pobreza disminuye 2.7 %. Efecto modesto pero significativo, reflejando que personas mayores acumulan capital humano y estabilidad laboral, reduciendo vulnerabilidad económica
- **HORASTRAB (horas trabajadas):** $\beta = +0,011$, $OR = 1.011$. Cada hora adicional de trabajo se asocia con 1.1 % mayor chance de pobreza. Efecto pequeño que refleja la estructura del mercado laboral argentino donde personas pobres trabajan más horas en empleos informales para compensar bajos salarios, sin que esto implique causalidad inversa

En cuanto a las variables categóricas, los efectos principales son:

- **CH04_2 (Mujer):** $OR = 0.733$. Las mujeres tienen 26.7 % menor chance de pobreza que los hombres, controlando por edad, horas trabajadas, educación y estado laboral. Esto puede reflejar sesgos de medición del IPCF a nivel hogar
- **Nivel educativo:** Mayor educación formal reduce sistemáticamente el riesgo de pobreza. Primaria completa (NIVEL_ED_2) muestra $OR = 0.576$ (-42.4 % vs sin instrucción), mientras niveles superiores muestran efectos protectores aún más fuertes
- **Estado laboral:** Desocupación (ESTADO_2) multiplica la chance de pobreza por 3.27 (+227.4 % vs ocupados), evidenciando que falta de empleo es el principal determinante de pobreza estructural
- **Categoría ocupacional:** Trabajadores cuenta propia (CAT_OCUP_3) tienen $OR = 4.011$ (+301.1 % vs patrón), reflejando heterogeneidad entre cuentapropistas profesionales e informales en contexto de alta precariedad

El gráfico de probabilidad predicha versus edad muestra tendencia decreciente moderada, con probabilidad promedio de pobreza cayendo de 35 % a 18 años hasta 25 % a 65 años. La variabilidad dentro de cada edad es amplia, reflejando que el estado laboral y educación son determinantes más fuertes que la edad per se.

Evaluación del umbral de decisión: Aunque el umbral estándar es 0.5, análisis posterior muestra que reducirlo a **0.4 maximiza cobertura** para programas sociales. Con umbral 0.4, el modelo Logit alcanza Recall de 82.6 % (capturando 336 de 407 pobres en test), aceptando Precisión de 44.4 % (483 falsos positivos). Esta configuración es óptima para política social donde el costo humanitario de excluir pobres (Error Tipo II) excede el costo fiscal de incluir no pobres (Error Tipo I).

3. K-Nearest Neighbors

K-Nearest Neighbors (KNN) es un algoritmo de aprendizaje supervisado no paramétrico que clasifica nuevas observaciones según la clase mayoritaria entre sus K vecinos más cercanos en el espacio de features. Formalmente, para un punto $\mathbf{x}_q$ a clasificar:

$$\hat{y}_q = \operatorname{argmax}_{c \in \{0,1\}} \sum_{i \in N_K(\mathbf{x}_q)} \mathbb{I}[y_i = c]$$

donde $N_K(\mathbf{x}_q)$ son los K vecinos más cercanos según distancia euclidiana:

$$d(\mathbf{x}_i, \mathbf{x}_q) = \sqrt{\sum_{j=1}^p (x_{ij} - x_{qj})^2}$$

A diferencia de la regresión logística, KNN no asume una forma funcional específica para la frontera de decisión, permitiendo capturar relaciones no lineales complejas. Sin embargo, esta flexibilidad tiene costos: alta sensibilidad a la escala de variables, curse of dimensionality, y ausencia de interpretabilidad directa de los predictores.

Mientras que la regresión logística puede manejar desbalanceo mediante pesos en la función de costo, KNN requiere un enfoque distinto ya que opera por voto mayoritario. Se aplicó **SMOTE** (Synthetic Minority Over-sampling Technique) para equilibrar parcialmente el dataset de entrenamiento con la siguiente configuración:

- **sampling_strategy = 0.7**: Ratio conservador que lleva la clase minoritaria (pobres) al 70 % del tamaño de la mayoritaria. Esto resulta en 3,023 obs originales → 3,059 obs (+36 ejemplos sintéticos, +1.2 %)
- **k_neighbors = 5**: Cada ejemplo sintético se genera interpolando entre un caso pobre real y uno de sus 5 vecinos pobres más cercanos
- **random_state = 444**: Garantiza reproducibilidad

Aplicar SMOTE con ratio 1.0 (balance perfecto 50-50) generaría aproximadamente 1,114 ejemplos sintéticos, aumentando el dataset 37 %. Experimentos preliminares mostraron que este oversampling agresivo produce overfitting severo: el modelo memoriza regiones sintéticas que no existen en la distribución real. El ratio 0.7 es un compromiso que mejora el recall en la clase minoritaria sin distorsionar excesivamente la distribución empírica. Se aplicó StandardScaler DESPUÉS de SMOTE ya que si se escala primero, los ejemplos sintéticos no estarían correctamente escalados.

El hiperparámetro K controla la flexibilidad del modelo y determina el balance entre sesgo y varianza:

- **K pequeño (K=1)**: Frontera de decisión muy irregular que se adapta perfectamente al training set, incluyendo ruido. Alta varianza, bajo sesgo
- **K grande (K=10+)**: Frontera suavizada que ignora patrones locales. Bajo varianza, alto sesgo

La evidencia empírica del trade-off se presenta en la siguiente tabla:

K	Acc Train	Acc CV (5-fold)	SD CV	Interpretación
1	100.0 %	69.8 %	0.8 %	Overfitting severo (30.2 pp gap)
3	78.2 %	71.1 %	0.7 %	Overfitting moderado
5	75.9 %	71.2 %	0.8 %	Mejora generalización
7	73.8 %	71.4 %	0.7 %	Óptimo: mejor CV, gap=2.4 pp
10	71.4 %	71.0 %	0.8 %	Comienza underfitting

Tabla 1: Trade-off sesgo-varianza según K. CV Accuracy mide generalización en datos no vistos.

El K=1 logra 100.0 % de accuracy en train pero solo 69.8 % en cross-validation, revelando overfitting catastrófico. A medida que K aumenta, la accuracy en train disminuye (el modelo se vuelve menos flexible) pero la CV accuracy aumenta hasta K=7, punto donde la generalización es óptima. Para K>7, ambas métricas decaen ligeramente, indicando que el modelo se vuelve demasiado rígido.

Para seleccionar K objetivamente, se evaluaron valores $K \in \{1, 2, \dots, 10\}$ mediante validación cruzada estratificada de 5 folds. En cada fold, el 80 % del training set se usa para ajustar KNN y el 20 % restante para evaluar, rotando los folds para que cada observación sea validada exactamente una vez. El **K óptimo resultó ser K=7**, con accuracy promedio de 71.4 % y desviación estándar

de 0.7 %. Este resultado es robusto: la baja SD indica que el desempeño es consistente entre folds. La curva de validación cruzada muestra claramente el patrón en U invertida característico del trade-off sesgo-varianza.

Para ilustrar el efecto de K en la geometría de la clasificación, se proyectaron las features en 2 dimensiones mediante PCA y se graficaron las fronteras de decisión para $K=1$, $K=5$ y $K=10$. $K=1$ produce regiones muy fragmentadas con "islas" de una clase rodeadas por otra, reflejando que el modelo clasifica basándose en un único vecino y amplificando outliers. $K=10$ genera fronteras suavizadas y regiones más amplias, menos sensibles a puntos individuales pero perdiendo capacidad de capturar estructuras locales complejas. $K=7$ representa un punto intermedio óptimo: mantiene flexibilidad local sin fragmentación excesiva.

4. Evaluación y Aplicación

Modelo	Acc	Prec	Recall	F1	AUC
Logit	0.714	0.504	0.693	0.583	0.746
KNN ($K=7$)	0.728	0.518	0.491	0.503	0.715

Tabla 2: Métricas comparativas en conjunto de prueba ($N=1,296$). Ver matrices confusión y curvas ROC en figuras correspondientes.

Ambos modelos presentan accuracy superior al 70 %, superando el baseline de clasificar todos como no pobres (68.5 % accuracy). Sin embargo, las diferencias sustanciales aparecen en recall y AUC, métricas más relevantes para el problema de focalización de políticas sociales. El análisis detallado de errores por tipo revela lo siguiente:

- **Falsos Positivos (Error Tipo I):** Clasificar a un no pobre como pobre implica asignarle beneficios sociales innecesariamente. El costo es financiero y moderado: presupuesto destinado a quien no lo necesita, generando ineficiencia en la focalización pero sin consecuencias humanitarias graves
- **Falsos Negativos (Error Tipo II):** Clasificar a un pobre como no pobre implica excluirlo de programas alimentarios, subsidios o asistencia social. El costo es humanitario y elevado: familias en situación de vulnerabilidad que no reciben ayuda enfrentan inseguridad alimentaria, deterioro de salud, y perpetuación del ciclo de pobreza
- **Logit (umbral 0.5):** 125 FN (30.7 % de los pobres no detectados) y 202 FP
- **KNN ($K=7$):** 207 FN (50.9 % de los pobres no detectados) y 137 FP
- **Diferencia crítica:** KNN excluye 82 pobres adicionales respecto a Logit, lo cual es significativo desde una perspectiva de política social

Las matrices de confusión visualizan estas diferencias: la diagonal principal (aciertos) es similar para ambos modelos, pero la celda FN (abajo-izquierda) es significativamente mayor en KNN. Las curvas ROC muestran AUC favorable para Logit (0.746 vs 0.715), indicando que Logit tiene superior capacidad de discriminación cuando se varía el umbral de decisión. Con umbral estándar de 0.5, Logit ofrece mejor balance para el problema específico de política social.

Para implementación en políticas de focalización de asistencia social, se recomienda la Regresión Logística por las siguientes razones:

1. **Recall superior:** 69.3 % vs 49.1 % (20.2 puntos porcentuales de diferencia). En términos absolutos, Logit detecta correctamente 282 pobres mientras que KNN solo 200, identificando 82 personas adicionales que necesitan asistencia
2. **F1-score superior:** 0.583 vs 0.503, indicando mejor balance entre precision y recall
3. **AUC superior:** 0.746 vs 0.715, confirmando mayor capacidad discriminativa del modelo
4. **Interpretabilidad y auditabilidad:** Los coeficientes de Logit permiten explicar las decisiones del modelo (ej: "esta persona fue clasificada como pobre porque está desocupada y tiene educación

primaria incompleta”). Esta transparencia es fundamental para rendir cuentas ante auditorías y para que los beneficiarios comprendan los criterios de elegibilidad. KNN es una “caja negra” que no ofrece justificaciones interpretables

5. **Priorización de FN sobre FP:** En contextos de asistencia social, el costo de excluir a un pobre (FN) supera ampliamente el costo de incluir a un no pobre (FP). Logit minimiza mejor los FN sin sacrificar excesivamente la precisión
6. **Robustez computacional:** Logit escala mejor a datasets grandes y no requiere almacenar todos los datos de entrenamiento para predicción, a diferencia de KNN

Aplicación a población no-respondiente. Un caso de uso crítico es predecir pobreza en los 2,857 individuos de Gran Buenos Aires que no reportaron IPCF pero tienen datos completos en las demás variables. Sin embargo, esta población presenta características sistemáticamente diferentes a los respondientes:

- **Edad media:** 40.3 años (no-respondientes) vs 38.6 años (respondientes)
- **Horas trabajadas:** 28.2 horas semanales vs 30.1 horas
- **Estado laboral:** Mayor proporción de inactivos en no-respondientes (37.7 % vs 33.5 %)

Estas diferencias sugieren **sesgo de selección no aleatorio**: las personas que no responden preguntas de ingreso no son una muestra aleatoria de la población, sino un subgrupo con características propias (posiblemente mayor informalidad laboral, menor confianza en instituciones, etc.).

Predicciones con umbral estándar 0.5:

- **Logit:** Predice 576 pobres (20.2 % de 2,857). Resultado conservador que sugiere aplicación prudente del modelo a población con características diferentes
- **KNN (K=7):** Predice 1,132 pobres (39.6 %). Resultado más cercano a la tasa de respondientes (31.5 %), aunque KNN tiende a ser más flexible en poblaciones heterogéneas
- **Tasa esperada:** Si aplicáramos la tasa de respondientes (31.5 %), esperaríamos 900 pobres. Logit subestima, KNN sobreestima

Lecciones sobre generalización y sesgo de selección. Este ejercicio ilustra una limitación fundamental de los modelos de Machine Learning: generalizan bien *dentro* de la distribución de entrenamiento, pero fallan cuando se aplican a poblaciones con características diferentes. El problema no es técnico (más datos o mejores algoritmos), sino estructural: los no-respondientes no son una muestra aleatoria.

Soluciones posibles: (1) Recolectar activamente datos de ingreso en población no-respondiente mediante seguimientos o incentivos, (2) Aplicar modelos de corrección de sesgo de selección como Heckman two-step que modelan explícitamente el proceso de no-respuesta, (3) Usar variables instrumentales que predicen la respuesta pero no la pobreza directamente.

Análisis de sensibilidad del umbral de clasificación. Los resultados presentados utilizan el umbral estándar de probabilidad 0.5 para clasificar (si $P(\text{Pobre}|X) > 0.5$, clasificar como pobre). Sin embargo, este umbral puede no ser óptimo para todos los contextos de política pública. El trade-off entre recall y precisión depende del presupuesto disponible y el costo relativo de los errores.

Se evaluaron tres umbrales para el modelo Logit en el conjunto de prueba (1,296 obs, 407 pobres reales):

Umbral	Predichos Pobres	VP	FP	Precision	Recall	F1
0.3	822	354	468	43.1 %	87.0 %	0.576
0.4	755	336	419	44.5 %	82.6 %	0.580
0.5	484	282	202	58.3 %	69.3 %	0.583

Tabla 3: Análisis de sensibilidad del umbral en modelo Logit.

Interpretación por escenario presupuestario:

- **Umbral 0.5 (estándar):** Maximiza F1-score y precision. Clasifica 484 como pobres (37.3 % del test), detectando 282 de 407 pobres reales (69.3 % recall) con 202 FP. Apropiado para presupuestos moderados que priorizan eficiencia fiscal
- **Umbral 0.4 (recomendado para política social):** Maximiza balance entre cobertura y eficiencia. Clasifica 755 como pobres (58.3 % del test), detectando 336 de 407 pobres reales (82.6 % recall) con 419 FP. Reduce exclusión de vulnerables en 54 personas (+19.1 %) respecto a umbral 0.5, aceptando 217 FP adicionales. **Óptimo para programas de asistencia alimentaria donde costo humanitario de FN excede costo fiscal de FP**
- **Umbral 0.3 (máxima cobertura):** Maximiza recall pero sacrifica precision excesivamente. Clasifica 822 como pobres (63.4 % del test), detectando 354 de 407 pobres (87.0 %) con 468 FP. Requiere presupuesto expandido y genera ineficiencias significativas

Aplicación del umbral 0.4 a no-respondientes (N=2,857):

- **Logit umbral 0.5:** 576 pobres predichos (20.2 %)
- **Logit umbral 0.4:** 956 pobres predichos (33.5 %), detectando 380 personas adicionales (+66 %)
- **Perfil del grupo marginal (0.4 < prob < 0.5):** Edad promedio 45.8 años, 73.9 % ocupados, 41.1 % secundaria completa. Población vulnerable en zona gris de elegibilidad donde pequeñas variaciones de circunstancias determinan pobreza
- **Sesgo de selección confirmado:** Tasa predicha 33.5 % en no-respondientes vs 31.5 % observada en respondientes sugiere que no-respondientes son población ligeramente más vulnerable, aunque diferencia es menor que con umbral 0.5 (factor 2.11x $\rightarrow$ 1.06x)

Esta flexibilidad del umbral es una ventaja operativa crucial: el mismo modelo puede adaptarse a restricciones presupuestarias cambiantes sin necesidad de re-entrenamiento. La curva ROC ilustra este trade-off continuo entre tasa de verdaderos positivos (recall) y tasa de falsos positivos a medida que varía el umbral.

5. Conclusiones

Este trabajo comparó dos algoritmos de Machine Learning para predicción de pobreza sin datos de ingreso: Regresión Logística (paramétrico) y K-Nearest Neighbors (no paramétrico). Los resultados muestran que, en contextos de política pública donde el costo de falsos negativos es elevado, la Regresión Logística ofrece ventajas sustanciales.

1. **Superioridad de Logit en recall:** La Regresión Logística detecta correctamente el 69.3 % de los pobres, mientras que KNN solo identifica el 49.1 %. Esta diferencia de 20.2 puntos porcentuales equivale a 82 personas adicionales que recibirían asistencia con Logit versus KNN. En programas alimentarios o de transferencias monetarias, donde excluir a un pobre (falso negativo) tiene costo humanitario irreversible (hambre, desnutrición infantil, abandono escolar), esta diferencia es determinante
2. **Factores de riesgo identificados:** El desempleo es el predictor más fuerte de pobreza (OR=3.27), seguido por ocupación cuenta propia (OR=4.01). Cada año adicional de edad reduce las chances de pobreza en 2.7 %. La educación muestra efecto protector consistente: primaria completa reduce el riesgo 42.4 % versus sin instrucción. Cada hora adicional de trabajo incrementa chances de pobreza en 1.1 %, reflejando que pobres trabajan más horas en empleos precarios
3. **Desempeño superior al esperado:** Ambos modelos alcanzan AUC entre 0.715 y 0.746, significativamente superior al azar (0.5). El modelo Logit (AUC=0.746) muestra capacidad discriminativa robusta, confirmando que variables socioeconómicas disponibles sin ingreso permiten identificar vulnerabilidad con precisión moderada-alta. Un recall del 69.3 % permite focalización ex-ante en más de dos tercios de los vulnerables, mejorando sustancialmente la eficiencia presupuestaria versus programas universales
4. **Interpretabilidad como ventaja decisiva:** Logit permite auditar decisiones mediante odds-ratios transparentes. KNN opera como caja negra sin justificaciones interpretables, lo cual es

problemático para rendir cuentas ante organismos de control y para que beneficiarios comprendan criterios de elegibilidad

Limitaciones del análisis:

- **Variables omitidas:** No se incluyeron variables del hogar (hacinamiento, tipo de vivienda, acceso a servicios básicos) ni geográficas (región, urbano/rural) que podrían mejorar el poder predictivo. La EPH contiene estas variables en el módulo hogar, y su incorporación podría elevar el AUC a 0.80-0.85
- **Sesgo de selección moderado:** Las predicciones sobre 2,857 no-respondientes presentan incertidumbre debido a que este grupo tiene características ligeramente diferentes (edad promedio 40.3 vs 38.6 años, mayor inactividad 37.7 % vs 33.5 %). Con umbral 0.4, el modelo predice 33.5 % de pobreza en no-respondientes versus 31.5 % observada en respondientes, sugiriendo población ligeramente más vulnerable
- **Validación temporal ausente:** Idealmente se debería entrenar con EPH Q4-2024 y validar en Q1-2025 para evaluar estabilidad temporal de los coeficientes ante cambios macroeconómicos (inflación, desempleo)
- **Umbral óptimo identificado:** El análisis demuestra que umbral 0.4 maximiza balance entre cobertura (82.6 % recall) y eficiencia (44.5 % precision), detectando 54 pobres adicionales versus umbral 0.5 (69.3 % recall). Esta configuración es recomendada para implementación en programas de asistencia social donde costo humanitario de FN excede costo fiscal de FP

Recomendaciones para implementación:

- **Adoptar Regresión Logística con umbral 0.4:** Implementar el modelo Logit con umbral ajustado a 0.4 para maximizar cobertura (82.6 % recall) en programas de asistencia social. Esta configuración detecta 54 pobres adicionales versus umbral estándar 0.5, aceptando 217 FP adicionales. La flexibilidad del umbral permite adaptar el modelo a cambios presupuestarios sin re-entrenamiento
- **Incorporar variables de hogar y vivienda:** Ampliar el conjunto de predictores con variables del cuestionario hogar EPH (NBI, hacinamiento, tipo de vivienda, acceso a servicios básicos) para mejorar discriminación del modelo. Estas variables podrían elevar el AUC de 0.746 a 0.80-0.85
- **Aplicar corrección de sesgo de selección:** Para la población no-respondiente (2,857 obs), implementar modelos Heckman two-step que modelen explícitamente el proceso de no-respuesta antes de predecir pobreza. Alternativamente, diseñar estrategias de seguimiento activo para recolectar datos de ingreso en esta población ligeramente más vulnerable
- **Actualización trimestral con validación temporal:** Re-entrenar modelos cada trimestre con nuevos datos EPH para capturar cambios en la estructura del mercado laboral y actualizaciones de la CBT. Implementar validación temporal: entrenar con trimestre T-1 y validar en T para evaluar estabilidad de coeficientes ante shocks macroeconómicos
- **Validación externa con registros administrativos:** Cruzar predicciones con bases de beneficiarios de programas sociales existentes (AUH, Tarjeta Alimentar, Potenciar Trabajo) para validar recall en campo. Esto permitiría detectar falsos negativos reales: personas clasificadas como no pobres por el modelo pero que efectivamente reciben asistencia
- **Auditoría y monitoreo continuo:** Establecer mecanismos de revisión humana para casos limítrofes (probabilidades entre 0.4-0.6) y monitorear métricas desagregadas por subgrupos demográficos (sexo, edad, región) para detectar posibles sesgos algorítmicos que afecten desproporcionadamente a poblaciones específicas

A. Anexo: Gráficos y Visualizaciones




Figura 1: Probabilidades estimadas por Regresión Logística vs Edad




Figura 2: Fronteras de decisión KNN: $K=1$ (izq.) vs $K=10$ (der.)




Figura 3: Optimización de K mediante validación cruzada




Figura 4: Matrices de confusión: Logit (izq.) y KNN (der.)




Figura 5: Curvas ROC comparativas