

Trabajo Práctico N° 4

Métodos de Regularización y CART para Predicción de Pobreza

Grupo 10 - Universidad de Buenos Aires - FCE

Noviembre 2025

Repositorio: <https://github.com/paulaleyleylen/BigDataUBA-GrupoJLP>

1. Regresión Logística con Regularización

El presente trabajo extiende el análisis del TP3 aplicando técnicas de regularización y árboles de decisión para predecir pobreza en la EPH 2025. El objetivo central es evaluar si métodos más sofisticados mejoran la capacidad predictiva respecto a los modelos base desarrollados previamente, considerando tanto la precisión estadística como la interpretabilidad requerida en contextos de política social.

La muestra de trabajo corresponde al primer trimestre de 2025 para Gran Buenos Aires, con 4.319 observaciones divididas en conjuntos de entrenamiento y prueba mediante partición 70 %-30 % estratificada. Las variables predictoras abarcan características demográficas (sexo, edad), educativas (nivel alcanzado), laborales (estado de actividad, horas trabajadas, categoría ocupacional), codificadas mediante variables dummy con eliminación de la primera categoría para evitar colinealidad perfecta, resultando en 17 features.

1.1. Visualización de coeficientes

La regularización introduce una penalización sobre la magnitud de los coeficientes del modelo, buscando controlar el sobreajuste mediante la restricción de la complejidad. Para explorar el comportamiento de LASSO y Ridge, se evaluó una grilla de valores $\lambda = 10^n$ con n variando entre -5 y 5 . En la implementación de scikit-learn, el parámetro de regularización se especifica como $C = 1/\lambda$, de modo que valores altos de C corresponden a penalizaciones débiles.

La trayectoria de coeficientes para LASSO exhibe un comportamiento característico: a medida que la penalización se intensifica, los coeficientes se contraen progresivamente hasta alcanzar exactamente cero. Esta propiedad de selección automática de variables es distintiva de la norma L_1 , que genera soluciones sparsas donde solo los predictores más informativos retienen valores no nulos. En nuestro análisis, las variables que sobreviven incluso con penalizaciones fuertes son NIVEL_ED_6, NIVEL_ED_5 y ESTADO_2, señalando la educación universitaria y el estado de desocupación como los predictores fundamentales.

El comportamiento de Ridge difiere sustancialmente. Los coeficientes convergen asintóticamente hacia cero pero nunca lo alcanzan, aplicando una contracción uniforme que reduce la magnitud de todos los predictores proporcionalmente sin eliminar ninguno. Esta característica

resulta útil para controlar multicolinealidad y reducir varianza, aunque no simplifica la interpretación final del modelo.

La diferencia entre ambos métodos responde a la geometría de sus restricciones: mientras la norma L1 genera una región factible en forma de rombo cuyos vértices intersectan los ejes de coeficientes, forzando soluciones donde algunos parámetros son exactamente cero, la norma L2 define una restricción circular sin puntos angulares sobre los ejes.

1.2. Selección de λ óptimo por validación cruzada

La elección del nivel óptimo de regularización se realizó mediante validación cruzada de 5 folds sobre el conjunto de entrenamiento, utilizando LogisticRegressionCV con accuracy como métrica de evaluación. Los resultados indican que LASSO alcanza su mínimo error de clasificación (28,5 %) con $\lambda = 0,1$ (equivalente a $C = 10$), mientras que Ridge optimiza con $\lambda = 10$ (equivalente a $C = 0,1$), logrando un error ligeramente inferior de 28,1 %.

Esta asimetría en los niveles de penalización óptimos refleja propiedades fundamentales de cada método. LASSO requiere penalización más débil porque su mecanismo de selección elimina variables rápidamente cuando la restricción se intensifica, provocando underfitting si se pierden predictores informativos. Ridge, por el contrario, tolera penalizaciones más fuertes dado que nunca elimina variables completamente, solo reduce su magnitud de forma proporcional.

1.3. Proporción de variables eliminadas por LASSO

El análisis de sparsidad muestra un comportamiento monótono creciente en la proporción de coeficientes nulos respecto al nivel de penalización. Con λ inferior a 0,1, LASSO retiene todas las variables; a partir de $\lambda = 1$, comienza a eliminar predictores progresivamente; y para $\lambda \geq 100$, más del 90 % de las variables son eliminadas, dejando prácticamente solo el intercepto.

Este resultado tiene implicancias directas para la interpretación del modelo óptimo. Dado que la validación cruzada seleccionó $\lambda = 0,1$, LASSO no eliminó ninguna variable en la especificación final. Aunque el método tiene capacidad inherente de selección, para este dataset particular la configuración óptima prefiere retener toda la información disponible. La eliminación agresiva de variables que se observa con penalizaciones mayores conlleva underfitting severo, confirmando que los 17 predictores contribuyen de forma significativa a la predicción de pobreza.

1.4. Comparación de coeficientes

La Tabla 1 presenta los coeficientes estimados para tres especificaciones: sin penalidad, LASSO y Ridge con sus respectivos λ óptimos. La comparación revela patrones distintivos en el efecto de cada tipo de regularización.

Variable	Sin Penalidad	LASSO (L1)	Ridge (L2)
Edad	-0,028	-0,028	-0,010
HORASTRAB	+0,011	+0,010	+0,005
Sexo	+0,082	+0,083	+0,081
NIVEL_ED_5	-1,209	-1,195	-0,436
NIVEL_ED_6	-1,435	-1,413	-0,612
ESTADO_2 (Desocupado)	+1,054	+1,037	+0,419
CAT_OCUP_1.0 (Patrón)	-2,165	-1,967	-0,380

Tabla 1: Coeficientes seleccionados: sin penalidad vs. LASSO vs. Ridge

Los coeficientes de LASSO resultan prácticamente idénticos a los del modelo sin penalidad, consecuencia directa del bajo nivel de regularización óptimo ($\lambda = 0,1$). Con penalización tan débil,

LASSO no modifica sustancialmente la solución de máxima verosimilitud, funcionando casi como un modelo logístico estándar.

Ridge exhibe un comportamiento marcadamente diferente. Se observa shrinkage significativo en todas las variables, con reducciones particularmente pronunciadas en los predictores con coeficientes originalmente grandes. El caso más extremo es CAT_OCUP_1.0 (ser patrón o empleador), cuyo coeficiente cae de $-2,16$ a $-0,38$, representando una contracción del 82 %. Este fenómeno refleja la “desconfianza” de Ridge hacia estimaciones extremas, especialmente cuando provienen de categorías con pocas observaciones donde la varianza muestral es alta.

Es importante destacar que Ridge no elimina ninguna variable: todos los coeficientes permanecen distintos de cero, confirmando que la penalidad L2 aplica contracción sin selección. La interpretación económica de los predictores se mantiene consistente entre especificaciones: la educación universitaria completa e incompleta reduce la probabilidad de pobreza, la desocupación la incrementa sustancialmente, y la categoría de patrón ejerce un efecto protector. La regularización modifica las magnitudes pero no altera las direcciones de los efectos estimados.

2. Árboles de Decisión (CART)

Los árboles de decisión constituyen una familia de métodos no paramétricos que particionan el espacio de predictores mediante reglas de decisión binarias sucesivas. A diferencia de la regresión logística, estos modelos no asumen linealidad ni requieren especificar una forma funcional a priori, lo que les permite capturar interacciones complejas y efectos no lineales de manera automática durante el proceso de construcción.

El algoritmo CART (Classification and Regression Trees) opera recursivamente, seleccionando en cada nodo la variable y punto de corte que maximiza la reducción de impureza. Para problemas de clasificación se utiliza habitualmente el índice de Gini, definido como $\text{Gini}(t) = 1 - \sum_{k=1}^K p_k^2$, donde p_k representa la proporción de observaciones de clase k en el nodo t . Un valor de Gini igual a cero indica pureza perfecta, con todas las observaciones perteneciendo a una única clase, mientras que Gini de 0,5 señala máxima impureza, con distribución equitativa entre clases.

2.1. Selección del hiperparámetro de poda

El parámetro `ccp_alpha` (Cost-Complexity Pruning alpha) gobierna el proceso de poda del árbol mediante un criterio que balancea ajuste y complejidad: $R_\alpha(T) = R(T) + \alpha \cdot |T|$, donde $R(T)$ es el error de clasificación, $|T|$ el número de hojas terminales, y α el costo por complejidad. Valores bajos de α permiten árboles profundos con riesgo de sobreajuste, mientras que valores altos generan árboles simples con potencial subajuste.

La selección del hiperparámetro óptimo se realizó mediante validación cruzada de 10 folds sobre una grilla de 20 valores entre 0 y 0,05, siguiendo las especificaciones de la consigna. El análisis indica que $\alpha^{cv} = 0,0026$ minimiza el error de validación, un valor cercano a cero que sugiere que el árbol óptimo requiere poda mínima. La curva de error presenta un patrón escalonado característico donde cada salto discreto corresponde a la eliminación de una rama significativa del modelo.

Este resultado contrasta con lo observado en regularización logística. Mientras que en LASSO y Ridge cierto nivel de penalización mejoraba la generalización, en CART la regularización mediante poda resulta contraproducente para este dataset específico. El árbol requiere mantener su estructura ramificada para capturar adecuadamente los patrones subyacentes de pobreza.

2.2. Diagnóstico de overfitting

Una preocupación natural ante un parámetro de poda tan bajo es la posibilidad de sobreajuste. Para evaluar esta hipótesis, se comparó el desempeño del modelo en los conjuntos de

entrenamiento y prueba. El árbol alcanza un accuracy de 72,9 % en entrenamiento y 71,8 % en prueba, lo que representa una diferencia de apenas 1,1 puntos porcentuales. Esta brecha reducida, inferior al umbral convencional del 5 %, indica que el modelo generaliza adecuadamente sin memorizar el conjunto de entrenamiento.

La estructura del árbol resultante refuerza esta conclusión. Con una profundidad de 6 niveles y únicamente 8 nodos terminales, el modelo exhibe parsimonia a pesar del bajo nivel de poda. Esta aparente paradoja se explica porque `ccp_alpha` no es el único mecanismo que limita la complejidad: las condiciones de parada del algoritmo (número mínimo de observaciones por hoja, máxima profundidad) también restringen el crecimiento del árbol.

2.3. Estructura e interpretación del árbol

El árbol podado revela una estructura de decisión coherente con la teoría económica sobre determinantes de pobreza. La primera partición separa a los menores de 18 años del resto de la población, reconociendo la vulnerabilidad diferencial de los jóvenes que presentan un índice de Gini de 0,50 en dicho nodo, indicando máxima incertidumbre en su clasificación.

Entre la población adulta, el árbol distingue inmediatamente a los universitarios completos, un grupo con probabilidad muy baja de pobreza (Gini = 0,16), del resto. Esta división temprana confirma el rol protector de la educación superior observado también en los modelos de regularización. Para quienes no completaron estudios universitarios, el siguiente criterio de partición es el estado laboral: los desocupados se separan de ocupados e inactivos, presentando alta concentración de pobreza.

Las divisiones posteriores refinan el análisis incorporando umbrales de edad (menores de 60 años versus adultos mayores) y distinguiendo la universitaria incompleta de niveles educativos inferiores. La secuencia de splits refleja una lógica de vulnerabilidad decreciente que prioriza primero la etapa vital, luego la formación educativa, y finalmente la situación laboral.

2.4. Importancia de variables

La métrica de importancia de variables, calculada como la reducción acumulada de impureza Gini ponderada por la proporción de observaciones que atraviesan cada nodo, ofrece una perspectiva complementaria a los coeficientes de regresión. La edad emerge como el predictor dominante, explicando el 42,7 % de la reducción total de impureza, resultado consistente con su aparición en múltiples niveles del árbol para capturar efectos del ciclo de vida.

La educación universitaria completa contribuye con el 16,1 % de la importancia, seguida de la universitaria incompleta (11,2 %), la desocupación (11,0 %) y las horas trabajadas (10,6 %). En conjunto, estos cinco predictores explican más del 90 % de la capacidad discriminativa del árbol. Las variables restantes, incluyendo sexo, niveles educativos intermedios y varias categorías ocupacionales, exhiben importancia nula, indicando que el árbol no las utilizó en ninguna partición.

2.5. Comparación con selección de variables en LASSO

La consigna plantea una pregunta relevante: ¿coinciden las variables eliminadas por LASSO con aquellas de menor importancia en el árbol? El análisis revela una situación particular: dado que el λ óptimo de LASSO fue bajo, ninguna variable fue eliminada en la especificación final. Sin embargo, las variables con coeficientes pequeños en LASSO tienden a coincidir con aquellas de importancia cero en el árbol, como `NIVEL_ED_3` (secundaria incompleta) y sexo.

La principal discrepancia aparece con `CAT_OCUP_1.0` (categoría de patrón o empleador), que presenta importancia nula en el árbol pero coeficiente alto en LASSO (-1,97). Esta divergencia refleja limitaciones del algoritmo de partición: la baja frecuencia de patrones en los nodos donde el

árbol toma decisiones impide que esta variable sea seleccionada para splits, aunque sí contribuye linealmente en el modelo logístico.

Por otra parte, edad y horas trabajadas muestran el patrón inverso: alta importancia en el árbol pero coeficientes moderados en regresión. Esta discrepancia sugiere relaciones no lineales que el árbol captura mediante múltiples cortes discretos (edad menor a 18, edad menor a 60) mientras los modelos lineales solo pueden representar con una única pendiente. Si se forzara mayor regularización en LASSO, probablemente NIVEL_ED_3, NIVEL_ED_4 y sexo serían las primeras variables eliminadas, coincidiendo con las menos informativas en el árbol.

3. Comparación entre Métodos

La evaluación comparativa de los cinco modelos desarrollados se realizó sobre el conjunto de prueba, compuesto por 1.296 observaciones de las cuales 407 corresponden a personas en situación de pobreza. Este conjunto incluye los dos modelos del TP3 (regresión logística sin penalidad con balanceo de clases y KNN con K=7 aplicando SMOTE) junto con los tres métodos nuevos: LASSO, Ridge y CART.

3.1. Métricas de desempeño

La Tabla 2 sintetiza las métricas de clasificación utilizando el umbral estándar de 0,5 para la decisión binaria. El análisis de estos resultados requiere considerar no solo la magnitud de cada métrica sino también su relevancia para el contexto específico de focalización de política social.

Modelo	Accuracy	Precision	Recall	F1	AUC
Logit TP3 (class_weight)	0.689	0.504	0.693	0.583	0.746
LASSO (L1)	0.715	0.577	0.342	0.429	0.746
Ridge (L2)	0.715	0.585	0.315	0.409	0.743
CART (Árbol)	0.718	0.581	0.371	0.452	0.731
KNN (K=7)	0.697	0.518	0.491	0.504	0.715

Tabla 2: Métricas de clasificación en conjunto de prueba ($N=1,296$). Umbral = 0.5.

CART lidera en accuracy con 71,8 %, seguido de cerca por LASSO y Ridge (71,5 %), pero esta métrica puede resultar engañosa en programas de asistencia social donde el costo de los errores es asimétrico. El contraste más notable aparece en recall: mientras que la regresión logística del TP3 detecta el 69,3 % de las personas pobres, LASSO apenas alcanza el 34,2 % y CART el 37,1 %. Esta diferencia implica que los modelos de regularización excluyen sistemáticamente a más de 140 personas pobres adicionales respecto al modelo con balanceo de clases.

Las curvas ROC revelan que la capacidad discriminativa, medida por el área bajo la curva, es similar entre los modelos logísticos: el TP3 y LASSO comparten un AUC de 0,746, mientras Ridge alcanza 0,743. CART presenta una curva ligeramente inferior ($AUC = 0,73$) con forma más escalonada debido a la naturaleza discreta de sus predicciones probabilísticas. KNN exhibe el desempeño más bajo ($AUC = 0,71$), confirmando que su flexibilidad no paramétrica no se traduce en ventaja predictiva para este problema.

3.2. Análisis de matrices de confusión

El examen detallado de las matrices de confusión permite cuantificar el trade-off entre tipos de error que subyace a las diferencias en recall. La descomposición se presenta en la Tabla 3.

La regresión logística del TP3 produce 125 falsos negativos, lo que equivale a no detectar el 30,7 % de las personas pobres. En contraste, LASSO genera 268 falsos negativos (65,8 % de pobres

Modelo	VP	FP	FN	VN
Logit TP3	282	278	125	611
LASSO	139	102	268	787
Ridge	128	91	279	798
CART	151	109	256	780
KNN	200	186	207	703

Tabla 3: Descomposición de errores: VP=Verdaderos Positivos, FP=Falsos Positivos, FN=Falsos Negativos, VN=Verdaderos Negativos

no detectados) y Ridge alcanza 279 (68,5 %). La diferencia de 143 personas entre Logit TP3 y LASSO tiene consecuencias directas en política social: cada falso negativo representa una familia que quedaría excluida de programas de asistencia alimentaria a pesar de necesitarla.

3.3. El balance entre linealidad y no linealidad

Los resultados desafían una expectativa teórica común: que los métodos no lineales deberían superar a los lineales cuando existen interacciones o efectos no monotónicos en los datos. Tanto CART como KNN muestran desempeño inferior o comparable a la regresión logística a pesar de su mayor flexibilidad funcional.

Esta observación sugiere que la estructura de pobreza en el Gran Buenos Aires puede aproximarse adecuadamente mediante relaciones log-lineales. El árbol CART efectivamente captura algunas interacciones, como la combinación de edad y educación en las primeras particiones, pero esta complejidad adicional no se traduce en mejor capacidad discriminativa global. KNN, por su parte, representa el peor modelo del conjunto a pesar de su naturaleza completamente no paramétrica, indicando que la cercanía en el espacio de predictores no constituye un criterio óptimo de clasificación para este problema.

3.4. Comunicación versus rendimiento predictivo

Los árboles de decisión ofrecen una ventaja distintiva en términos de interpretabilidad: la estructura del modelo puede visualizarse y explicarse a tomadores de decisión sin formación técnica en estadística. Un funcionario del Ministerio de Capital Humano puede comprender intuitivamente que “los menores de 18 años son más vulnerables” o que “los desocupados no universitarios presentan alto riesgo de pobreza”. Esta transparencia contrasta con los coeficientes de regresión y los odds-ratios que requieren mayor sofisticación para su interpretación.

Sin embargo, la ganancia en comunicabilidad tiene un costo: CART sacrifica aproximadamente 1,5 puntos de AUC y más de 30 puntos porcentuales de recall respecto al modelo logístico balanceado. KNN, por su parte, funciona como una caja negra sin ventajas ni en comunicación ni en rendimiento, lo que lo descarta como alternativa viable.

3.5. Recomendación para focalización de asistencia social

En el diseño de programas de asistencia alimentaria, los costos asociados a cada tipo de error difieren sustancialmente. Un falso negativo implica excluir del programa a una familia que efectivamente lo necesita, con consecuencias humanitarias potencialmente irreversibles: hambre, desnutrición infantil, deterioro de la salud. Un falso positivo significa incluir a una familia que no cumple los criterios de elegibilidad, generando un costo fiscal que, aunque indeseable, resulta recuperable mediante ajustes posteriores del programa.

Esta asimetría fundamenta la recomendación de priorizar el modelo con mayor recall. La regresión logística del TP3, especificada con balanceo de clases mediante el parámetro `class_weight`,

detecta 282 de las 407 personas pobres en el conjunto de prueba, equivalente a una cobertura del 69,3 %. LASSO, a pesar de su mayor accuracy, identificaría solamente 139 pobres, excluyendo a 143 personas que deberían recibir asistencia.

El diseño del modelo logístico balanceado penaliza más fuertemente los errores en la clase minoritaria, alineando el objetivo de la función de pérdida con el objetivo de política pública. Adicionalmente, dado que este modelo alcanza el mejor AUC (0,746), permite ajustar el umbral de decisión según el presupuesto disponible sin necesidad de reentrenar: reduciendo el threshold de 0,5 a 0,4, como se demostró en el TP3, la cobertura se elevaría al 82,6 % a costa de mayor inclusión de falsos positivos.

La recomendación formulada en el TP3 a favor de la regresión logística sobre KNN se mantiene y refuerza con los resultados del presente análisis. Los modelos de regularización, si bien ofrecen mejor accuracy global, sacrifican precisamente la métrica que resulta prioritaria para política social: la capacidad de identificar a quienes más necesitan asistencia.

3.6. Síntesis de hallazgos

El análisis de regularización reveló que tanto LASSO como Ridge encuentran su nivel óptimo de penalización en valores que no modifican sustancialmente la estructura del modelo original. El λ bajo de LASSO indica que todas las variables aportan información relevante, mientras el shrinkage de Ridge reduce la magnitud de coeficientes extremos sin mejorar el recall en prueba.

CART ofrece una representación interpretable de los determinantes de pobreza, identificando la edad como predictor dominante seguido de la educación universitaria y el estado laboral. Sin embargo, su recall de 37,1 % resulta inaceptable para política social, excluyendo a casi dos tercios de la población objetivo.

No se encontró evidencia de ventaja por utilizar métodos no lineales en este problema. Los patrones de pobreza en el Gran Buenos Aires exhiben una estructura aproximadamente log-lineal que los modelos paramétricos capturan de manera eficiente. Para la implementación práctica de un sistema de focalización, se recomienda mantener la regresión logística con balanceo de clases, considerando reducir el umbral de decisión si el presupuesto permite mayor cobertura con la consecuente inclusión de algunos beneficiarios no elegibles.

A. Anexo: Gráficos y Visualizaciones




Figura 1: Trayectoria de coeficientes LASSO (L1) y Ridge (L2) en función de $\log_{10}(\lambda)$




Figura 2: Error de clasificación promedio (5-Fold CV) vs. penalidad λ para LASSO y Ridge




Figura 3: *Proporción de variables eliminadas por LASSO en función de λ*




Figura 4: *Error de clasificación vs. costo de complejidad (ccp_alpha) en árbol CART*




Figura 5: Árbol de decisión podado (ccp_alpha=0.0026)




Figura 6: Importancia de variables (Gini) en el árbol CART




Figura 7: *Curvas ROC comparativas: todos los modelos*




Figura 8: *Matrices de confusión: LASSO, Ridge y CART*